

گزارش نهایی پروژه تشخیص نوع عیب ورق فولادی

Team 3 · FINAL AUDIT V9

این نسخه بر اساس صورت پروژه رسمی بازبینی شده و دو ایراد روش شناختی شناسایی شده در نسخه قبلی اصلاح شده است.

اصلاح ۱: Filter و GA پس از انتخاب روی Train، دیگر با همان Train برای رتبه بندی نهایی Cross-Validation نمی شوند؛ رتبه بندی نهایی روی Validation مستقل انجام می شود.

اصلاح ۲: Boxplot نوت بوک مرجع به تفکیک کلاس تولید می شود.

مقدار	شاخص
1941	نمونه ها
27	ویژگی های مستقل
7	کلاس ها
Train / 291 Validation / 292 Test 1358	تقسیم
RandomForest + All_27	مدل نهایی
0.8298	Test Macro F1
0.8197	Test Balanced Accuracy

نتیجه علمی: در این داده، GA اجرا و ارزیابی شد، اما شواهد Validation از حذف ویژگی بدون افت عملکرد حمایت نمی کند؛ بنابراین هر ۲۷ ویژگی در مدل نهایی حفظ شده اند.

۲. شناخت داده و کنترل کیفیت

داده Steel Plates Faults شامل ۱۹۴۱ نمونه، ۲۷ ویژگی و ۷ ستون هدف One-Hot است. برای هر ردیف مجموع ستون‌های هدف دقیقاً یک بوده است.





percentage	count	class
8.140133951571354	158	Pastry
9.788768675940238	190	Z_Scratch
20.14425553838228	391	K_Scratch
3.709428129829985	72	Stains
2.833590932509016	55	Dirtiness
20.71097372488408	402	Bumps
34.672849046883044	673	Other_Faults

تقسیم داده

تقسیم Stratified با نسبت تقریبی 70/15/15 انجام شده و Test تا پایان انتخاب مدل و ویژگی دست‌نخورده باقی مانده است.

۳. تحلیل آماری و تصویری


برای بیش از هفت ویژگی، Min، Max، Mean، Standard Deviation، Median و صدک‌های 25، 50، 75 و 90 محاسبه شده‌اند.



Boxplot به تفکیک کلاس تولید شده و Scatterها برای نمایش هم‌پوشانی ویژگی‌ها استفاده شده‌اند.

۴. نقاط پرت، مقاوم سازی و نويز

نقاط پرت سراسری و درون هر کلاس بررسی شدند و هیچ رکوردی صرفاً به علت عبور از یک آستانه آماری حذف نشده است.



مقایسه مقاوم سازی

accuracy	balanced_accuracy	macro_f1	strategy
0.6529209621993127	0.7325907485189054	0.6455907719261582	StandardScaler_Logistic
0.6563573883161512	0.7350538027060975	0.6466287835916683	RobustScaler_Logistic
0.6597938144329897	0.7364682298630989	0.6489509639539176	Winsorize1to99_RobustScaler_Logistic


حساسیت نويز

recall_Stains	recall_Dirtiness	balanced_accuracy	macro_f1	noise_level
0.8181818181818182	0.8888888888888888	0.8026088217548004	0.8288470468293341	0.0
0.8181818181818182	0.7777777777777778	0.7744909079226007	0.8030498804808529	0.01
0.8181818181818182	0.6666666666666666	0.7018151709611496	0.7449811272471372	0.05
0.8181818181818182	0.6666666666666666	0.670942337020472	0.7145004151357911	0.1

۵. مدل سازی و تنظیم ابرپارامتر

خط پایه اکثریت، Logistic Regression و Random Forest مقایسه شدند. تنظیم ابرپارامتر با RandomizedSearchCV و Stratified 5-Fold فقط روی Train انجام شد.

معیار اصلی Macro F1 است؛ Balanced Accuracy و معیارهای هر کلاس نیز گزارش می‌شوند.



الگوریتم ژنتیک

کروموزوم ۲۷ بیتی، جریمه تعداد ویژگی و سه seed مستقل (11,22,33) استفاده شد.

Seed	Number of features	Fitness	CV Macro F1
11.0	19.0	0.6420035510046507	0.6490405880416877
22.0	18.0	0.6255647193746438	0.6322313860413105
33.0	19.0	0.6444388920868728	0.6514759291239098

Class-weight impact (Validation diagnostic; tree count fixed at 80)

Class Weight	Macro F1	Balanced Acc.	Accuracy	Interpretation
None	0.7970	0.7933	0.7979	Validation only
balanced	0.8129	0.7894	0.8014	Validation only
balanced_subsample	0.8191	0.7874	0.8048	Validation only

Per-class Recall (Validation):

Weight	Pastry	Z_Scratch	K_Scratch	Stains	Dirtiness	Bumps	Other_Faults
None	0.391	0.862	0.932	0.818	1.000	0.738	0.812
balanced	0.391	0.828	0.932	0.818	1.000	0.705	0.851
balanced_subsample	0.391	0.793	0.949	0.818	1.000	0.689	0.871

This diagnostic documents the required class-weight impact. The final model uses balanced_subsample; Test was not used for this comparison.

HYPERPARAMETER SEARCH EVIDENCE (TRAIN ONLY)

Method: RandomizedSearchCV | scoring: Macro F1 | Stratified 5-Fold | CV shuffle seed: 42 | search seed: 2026
Logistic: C={0.1, 0.5, 1, 2, 5}, solver=lbfgs | budget=5 | runtime?1.44 s
Random Forest: n_estimators={50,80}, min_samples_leaf={1,2,4}, max_features={sqrt,0.5} | budget=3 | runtime?5.30 s
Best configurations are selected without using Test. Test is evaluated once after all selections are frozen.

۶. انتخاب نهایی کاندیدها – نسخه اصلاح شده

چون Filter و GA از Train یاد گرفته اند، استفاده دوباره از همان Train-CV برای رتبه بندی نهایی می تواند برآورد خوش بینانه ایجاد کند. بنابراین کاندیدها روی Validation مستقل رتبه بندی شدند.

Validation Balanced Acc	Validation Macro F1	Features	Candidate	Model
0.8026088217548004	0.8288470468293341	27	All_27	RandomForest_Nonlinear
0.7818917993136401	0.8168161806229735	19	GA_33	RandomForest_Nonlinear
0.7783203707422114	0.8002126593625399	21	Filter	RandomForest_Nonlinear
0.7669001488466931	0.7853700293135493	18	GA_22	RandomForest_Nonlinear
0.7429177506068693	0.7706190304553271	19	GA_11	RandomForest_Nonlinear
0.745458977635976	0.6481946624803767	19	GA_33	Logistic_Interpretable
0.7340051756759067	0.6463784559756266	21	Filter	Logistic_Interpretable
0.7336393755490961	0.6444296155708307	27	All_27	Logistic_Interpretable
0.7303285360203858	0.6382656325579281	18	GA_22	Logistic_Interpretable
0.7245520875099473	0.629017758618599	19	GA_11	Logistic_Interpretable


برنده Validation: RandomForest_Nonlinear + All_27, با Macro F1 = 0.8288.

نتیجه علمی این است که GA ارزش افزوده لازم برای حذف ویژگی را در این تقسیم داده نشان نداده است.

۷. ارزیابی نهایی Test

پس از فریز انتخاب‌ها، مدل روی Train+Validation برارش شد و فقط یک‌بار روی Test ارزیابی شد.

FN	Support	F1	Recall	Precision	کلاس
11	23	0.533	0.522	0.545	Pastry
3	29	0.929	0.897	0.963	Z_Scratch
4	59	0.948	0.932	0.965	K_Scratch
2	11	0.857	0.818	0.900	Stains
0	8	1.000	1.000	1.000	Dirtiness
13	61	0.774	0.787	0.762	Bumps
22	101	0.767	0.782	0.752	Other_Faults



81.25% :Weighted F1 — 82.98% :Macro F1 — 81.97% :Balanced Accuracy — 81.16% :Accuracy

۸. خطاها، ریسک‌ها و جمع‌بندی

دو جفت خطای اصلی

- **Bumps ↔ Other_Faults**: 22 خطای رفت و برگشتی (10 و 12).
- **Pastry ↔ Other_Faults**: 15 خطای رفت و برگشتی (8 و 7).

کلاس‌های پرهزینه

Dirtiness با $\text{Recall} = 1.000$ و صفر FN ؛ Stains با $\text{Recall} = 0.818$ و دو FN .

محدودیت‌ها

- تعمیم به کارخانه یا دورین دیگر با داده خارجی آزمایش نشده است.
- کلاس‌های کم‌نمونه عدم قطعیت بیشتری دارند.
- GA زیرمجموعه‌های 18-19 ویژگی تولید کرد، اما در Validation بهتر از All_27 نبود.

نتیجه نهایی

سامانه به‌عنوان ابزار کمک به بازررس انسانی تعریف می‌شود، نه جایگزین کنترل کیفیت. انتخاب نهایی قبل از مشاهده Test انجام شده است.

نسخه اصلاح‌شده — اکتبر 2026